

Máster Universitario en Investigación en Inteligencia Artificial

SEGMENTACIÓN SEMÁNTICA EFICIENTE PARA DETECCIÓN DE TUMORES EN ECOGRAFÍAS MAMARIAS EN TIEMPO REAL

González-Novo Hueso, Jaime
Director: Cuadra Troncoso, José Manuel

Universidad Nacional de Educación a Distancia

Septiembre 2024

Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

- Materiales
- Métodos

4 Resultados

- Métricas obtenidas
- Comparación con el estado del arte
- Análisis visual
- Tiempo Real

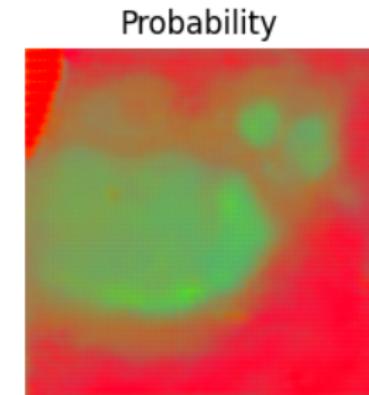
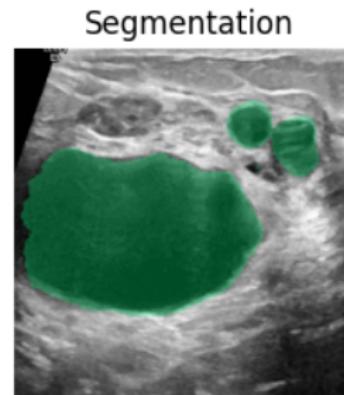
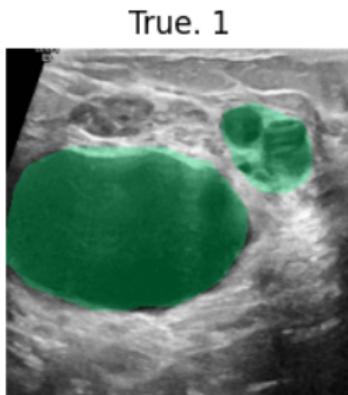
5 Conclusiones y Trabajos Futuros

Índice

- 1 Introducción
- 2 Estado del Arte
- 3 Materiales y Métodos
- 4 Resultados
- 5 Conclusiones y Trabajos Futuros

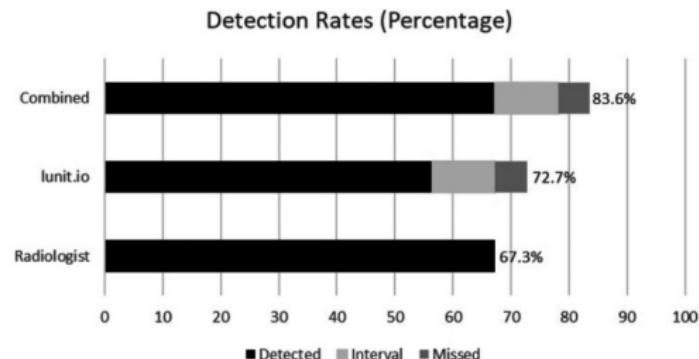
Resumen

Segmentación semántica para detección de tumores mamarios en imágenes de ultrasonido con aprendizaje profundo basado en la arquitectura EFSNet para la obtención de un modelo de baja latencia y bajo coste computacional para inferencia en tiempo real.



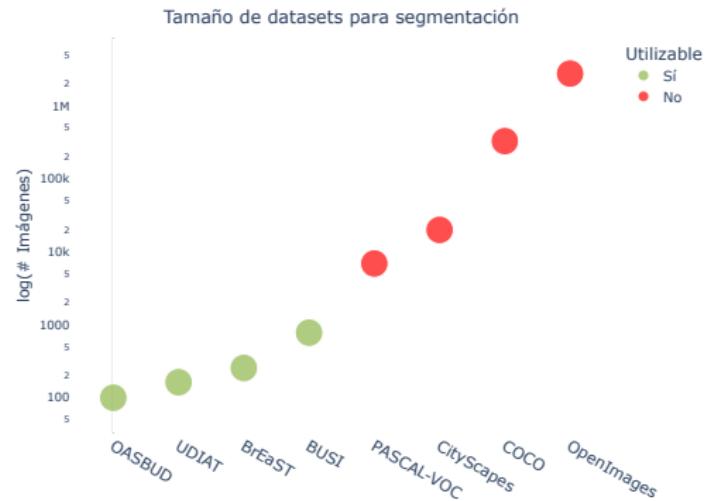
Desafíos

- Problema de alta complejidad.
- Datos escasos.
- Reducción del número de parámetros.



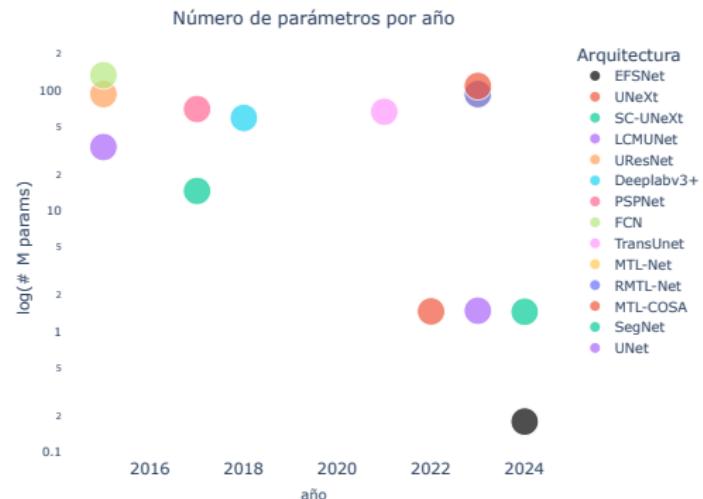
Desafíos

- Problema de alta complejidad.
- Datos escasos.
- Reducción del número de parámetros.



Desafíos

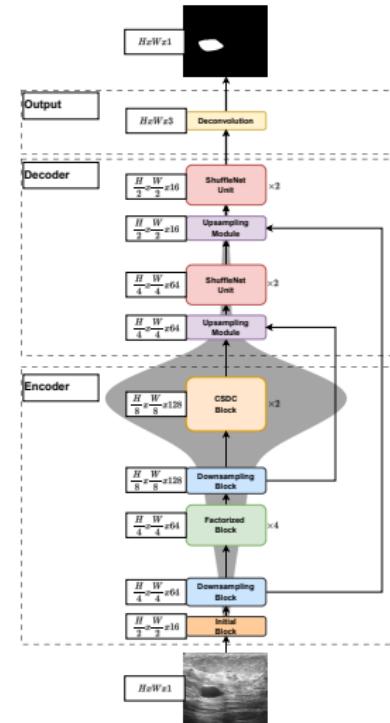
- Problema de alta complejidad.
- Datos escasos.
- Reducción del número de parámetros.



Propuesta y objetivos

Solución basada en EFSNet

- Predicciones a la altura del estado del arte.
- Bajo coste computacional sin pérdida de efectividad.
 - 179k parámetros
 - 143Mb de RAM en inferencia
- Uso en tiempo real.

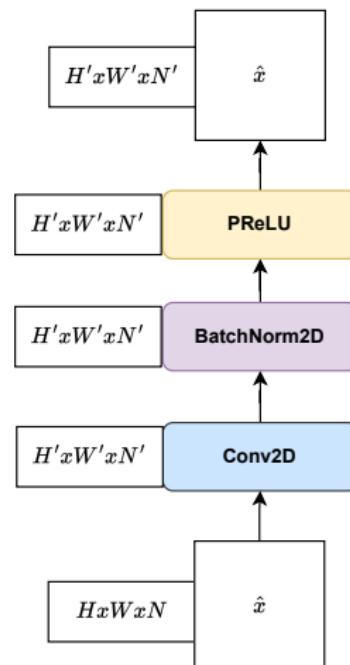


Índice

- 1 Introducción**
- 2 Estado del Arte**
- 3 Materiales y Métodos**
- 4 Resultados**
- 5 Conclusiones y Trabajos Futuros**

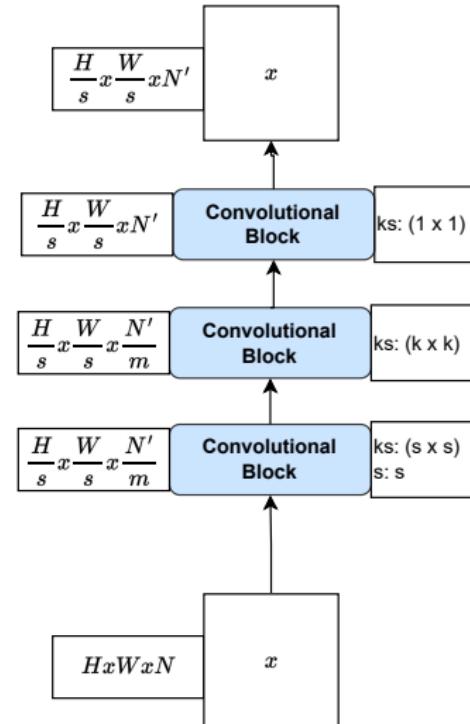
Eficiencia computacional

- *BatchNorm* y activación *PReLU*.
- Capas de convolución desagregadas.
- Convolución por grupo y barajado de canales.
- Regularización dropout en los canales. *SpatialDropout*.
- Bloques residuales y *skip-connections*.



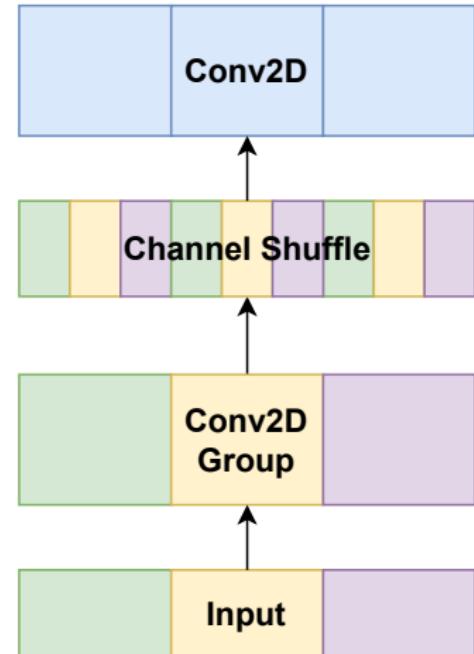
Eficiencia computacional

- *BatchNorm* y activación *PReLU*.
- Capas de convolución desagregadas.
- Convolución por grupo y barajado de canales.
- Regularización dropout en los canales. *SpatialDropout*.
- Bloques residuales y *skip-connections*.



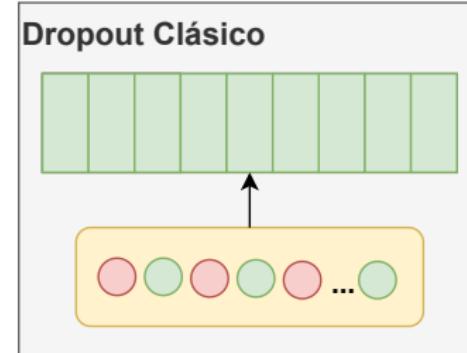
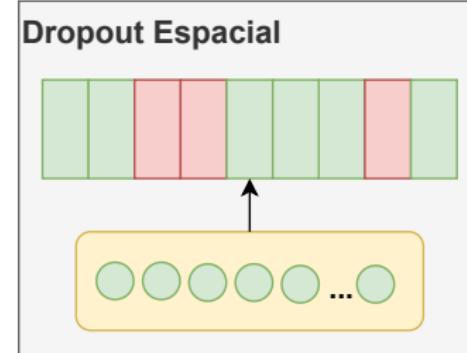
Eficiencia computacional

- *BatchNorm* y activación *PReLU*.
- Capas de convolución desagregadas.
- Convolución por grupo y barajado de canales.
- Regularización dropout en los canales. *SpatialDropout*.
- Bloques residuales y *skip-connections*.



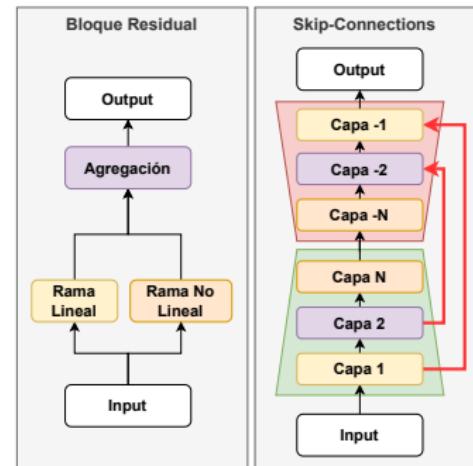
Eficiencia computacional

- *BatchNorm* y activación *PReLU*.
- Capas de convolución desagregadas.
- Convolución por grupo y barajado de canales.
- Regularización dropout en los canales. *SpatialDropout*.
- Bloques residuales y *skip-connections*.



Eficiencia computacional

- *BatchNorm* y activación *PReLU*.
- Capas de convolución desagregadas.
- Convolución por grupo y barajado de canales.
- Regularización dropout en los canales. *SpatialDropout*.
- Bloques residuales y *skip-connections*.



Actualización del estado del arte

Decalaje en la reducción de parámetros

- El estado del arte sigue utilizando bloques de exprimido y excitación obsoletos
- No existen implementaciones de convoluciones por grupo con barajado de canales
- No se observa el uso de Dropout Espacial
- No se observa la combinación de Normalización por lote con activación PReLU

Implementación de mejoras

Utilización de EFSNet con bloques eficientes, mayor reducción de parámetros y mejor efectividad.

Actualización del estado del arte

Decalaje en la reducción de parámetros

- El estado del arte sigue utilizando bloques de exprimido y excitación obsoletos
- No existen implementaciones de convoluciones por grupo con barajado de canales
- No se observa el uso de Dropout Espacial
- No se observa la combinación de Normalización por lote con activación PReLU

Implementación de mejoras

Utilización de EFSNet con bloques eficientes, mayor reducción de parámetros y mejor efectividad.

Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

- Materiales
- Métodos

4 Resultados

5 Conclusiones y Trabajos Futuros

Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

■ Materiales

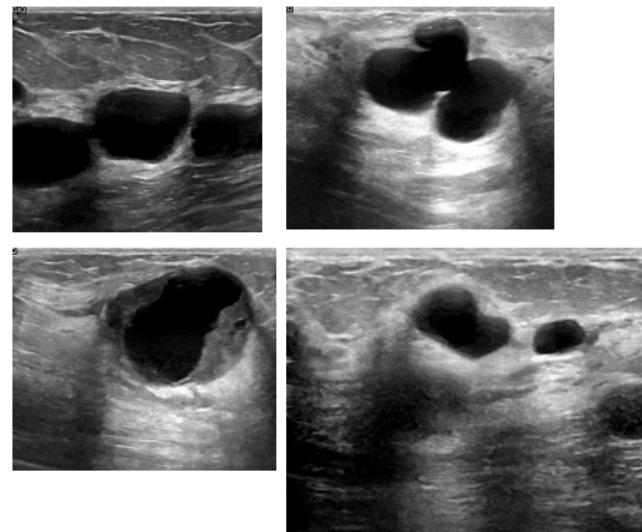
■ Métodos

4 Resultados

5 Conclusiones y Trabajos Futuros

Datos

- Dataset of Breast Ultrasound Images, *BUSI*.
 - 780 imágenes.
 - Distintas dimensiones.
 - Aberraciones y duplicidades.
- Transformaciones iniciales.
 - Redimensión de imágenes a (512x512).
 - Unión de máscaras.
- Desbalance de clases.



Datos

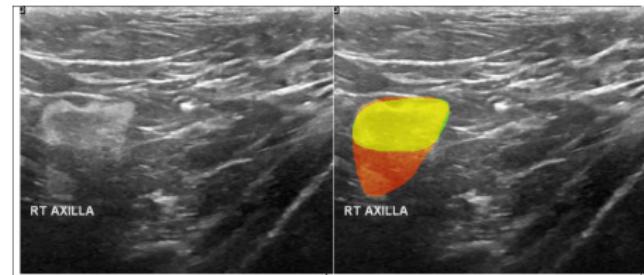
- Dataset of Breast Ultrasound Images, *BUSI*.

- 780 imágenes.
 - Distintas dimensiones.
 - Aberraciones y duplicidades.

- Transformaciones iniciales.

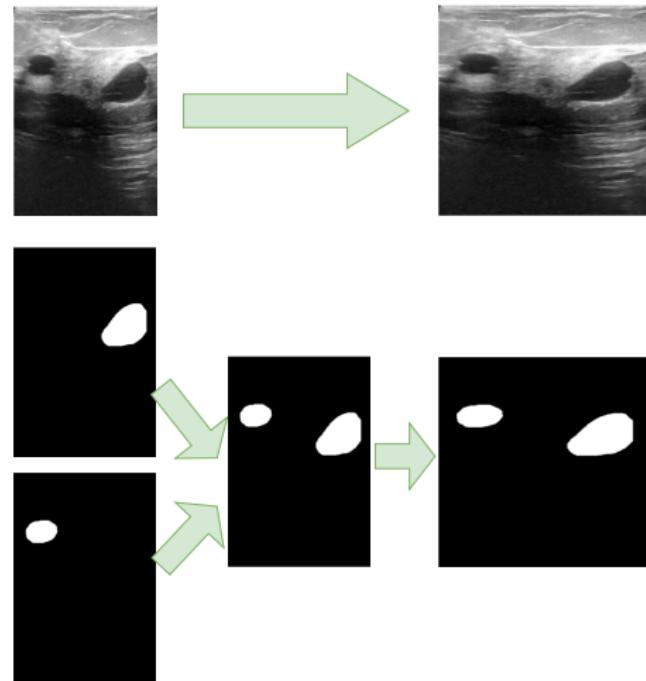
- Redimensionamiento de imágenes a (512x512).
 - Unión de máscaras.

- Desbalance de clases.



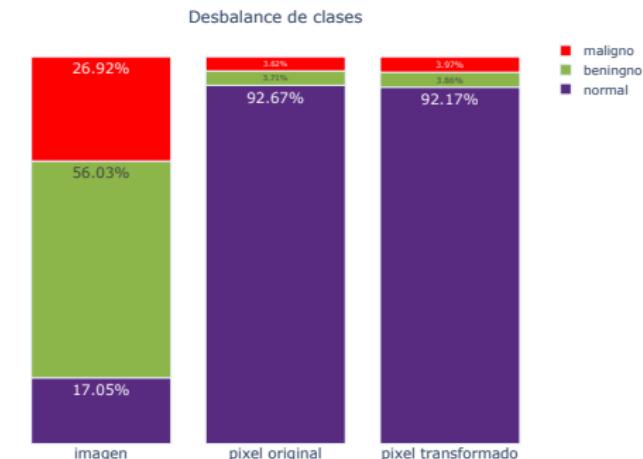
Datos

- Dataset of Breast Ultrasound Images, *BUSI*.
 - 780 imágenes.
 - Distintas dimensiones.
 - Aberraciones y duplicidades.
- Transformaciones iniciales.
 - Redimensión de imágenes a (512x512).
 - Unión de máscaras.
- Desbalance de clases.



Datos

- Dataset of Breast Ultrasound Images, *BUSI*.
 - 780 imágenes.
 - Distintas dimensiones.
 - Aberraciones y duplicidades.
- Transformaciones iniciales.
 - Redimensión de imágenes a (512x512).
 - Unión de máscaras.
- Desbalance de clases.



Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

- Materiales
- Métodos

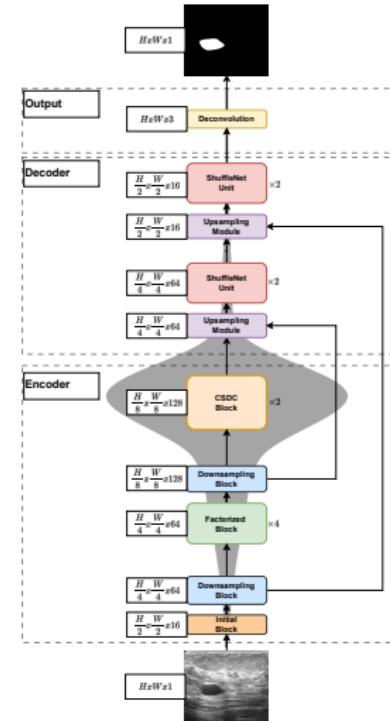
4 Resultados

5 Conclusiones y Trabajos Futuros

EFSNet

EFSNet. *Efficient Fast Semantic Segmentation Network*.

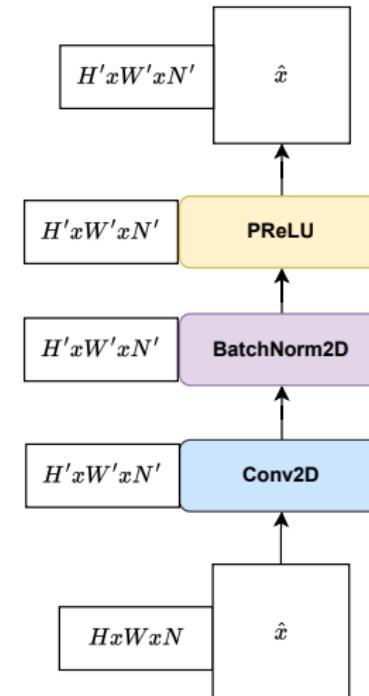
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

- EFSNet. *Efficient Fast Semantic Segmentation Network.*

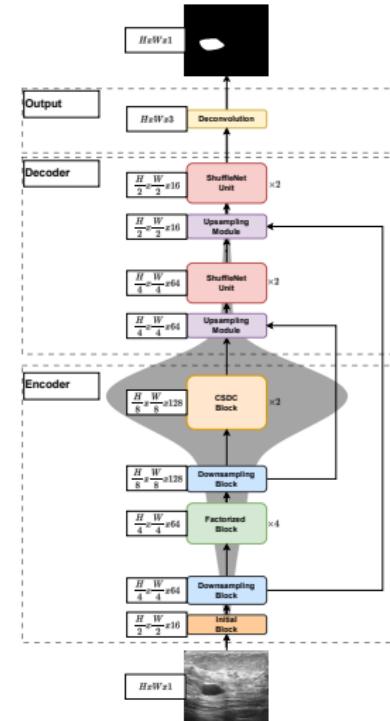
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- ShuffleNet Unit*.
- Predicción.



EFSNet

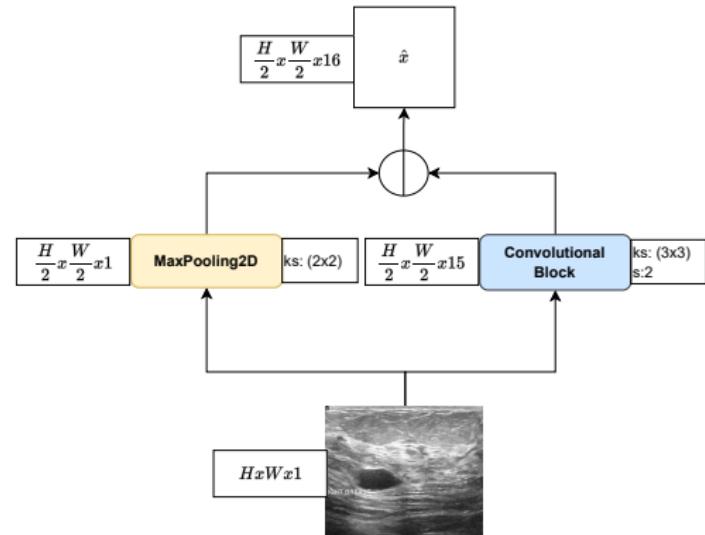
EFSNet. *Efficient Fast Semantic Segmentation Network*.

- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

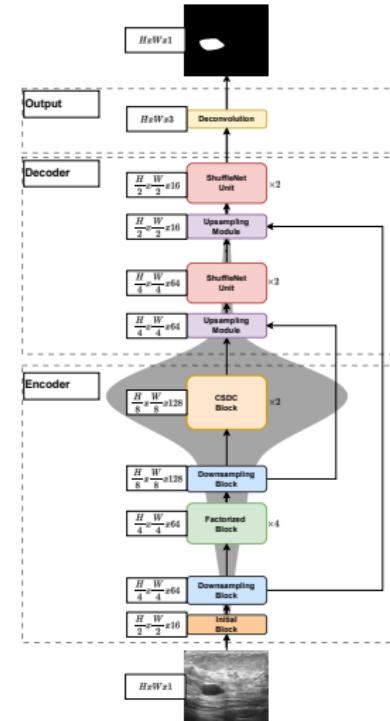
- EFSNet. *Efficient Fast Semantic Segmentation Network.*
 - Bloque Convolucional.
 - Bloque Inicial.
 - Bloque *Downsampling*.
 - Bloque Factorizado.
 - Bloque CSDC.
 - Bloque SDC.
 - Módulo *Upsampling*.
 - *ShuffleNet Unit*.
 - Predicción.



EFSNet

- EFSNet. *Efficient Fast Semantic Segmentation Network.*

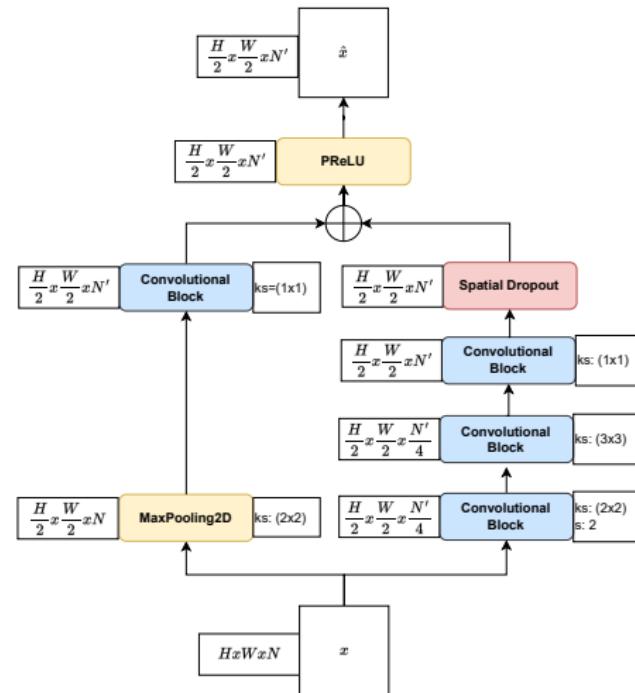
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

- EFSNet. *Efficient Fast Semantic Segmentation Network.*

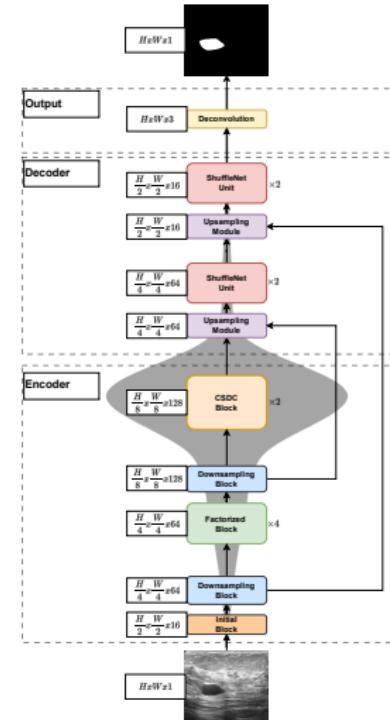
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- ShuffleNet Unit*.
- Predicción.



EFSNet

EFSNet. *Efficient Fast Semantic Segmentation Network*.

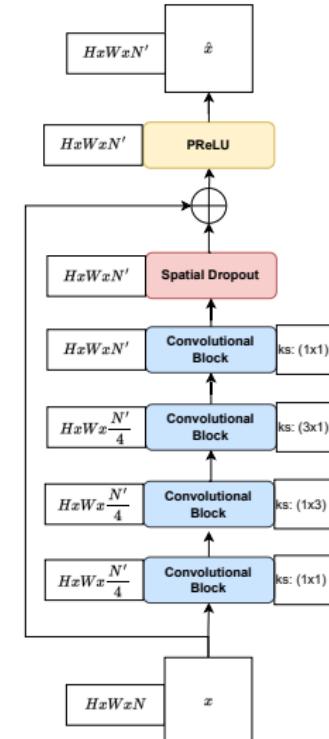
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

- EFSNet. *Efficient Fast Semantic Segmentation Network.*

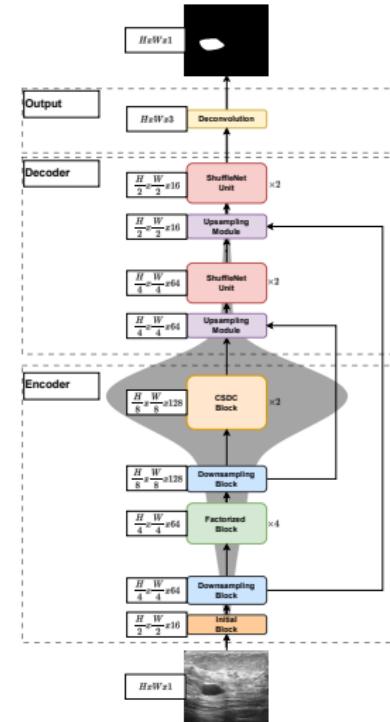
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- ShuffleNet Unit.*
- Predicción.



EFSNet

EFSNet. *Efficient Fast Semantic Segmentation Network*.

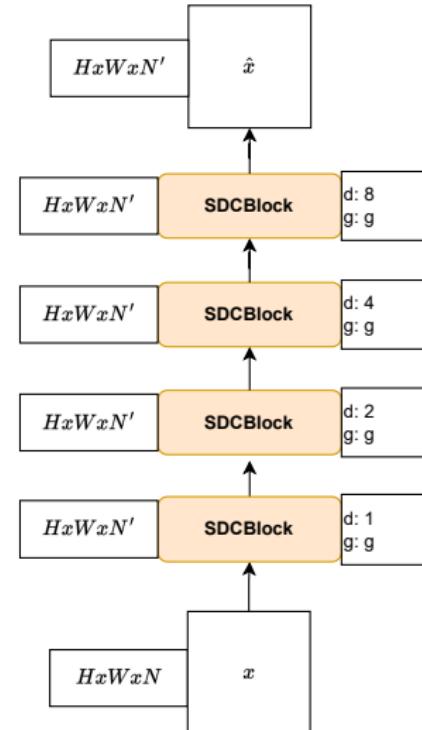
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

- EFSNet. *Efficient Fast Semantic Segmentation Network.*

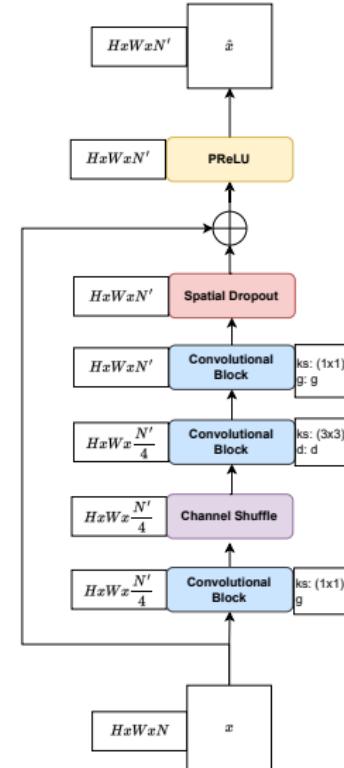
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

- EFSNet. *Efficient Fast Semantic Segmentation Network.*

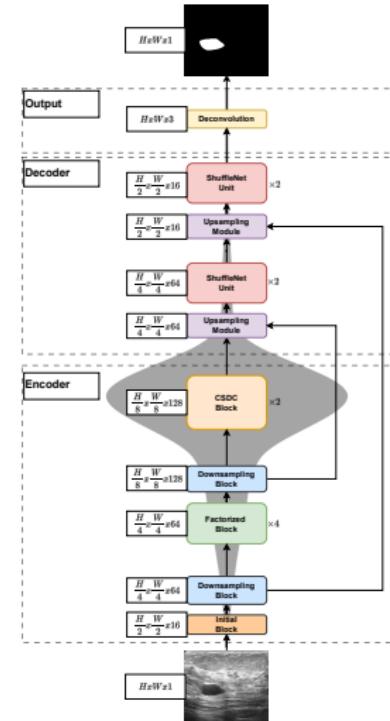
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

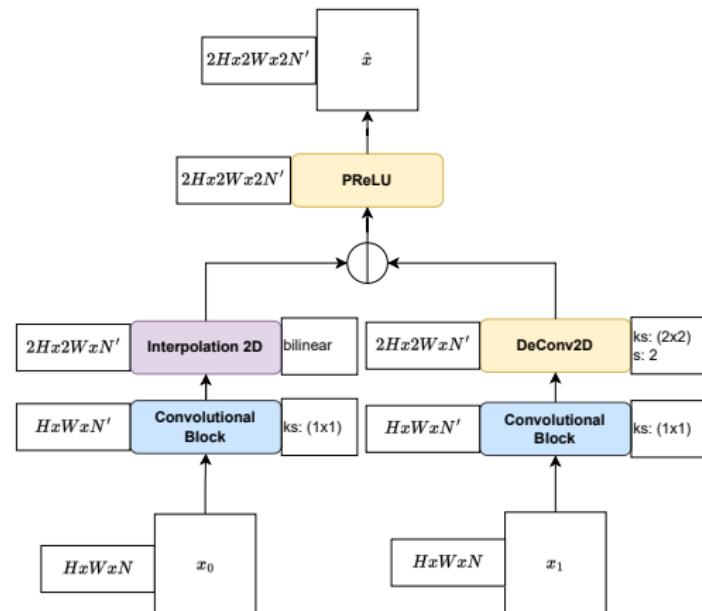
EFSNet. *Efficient Fast Semantic Segmentation Network*.

- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

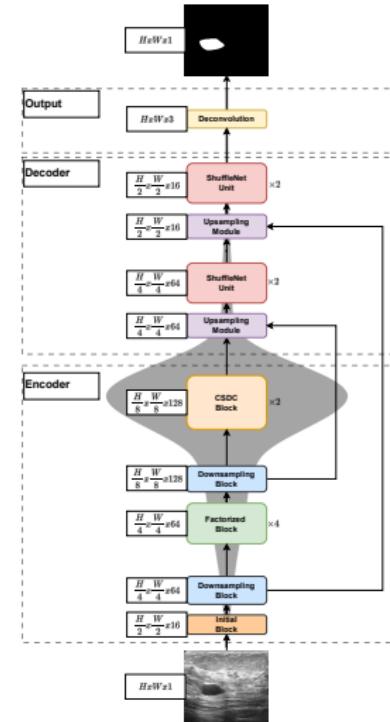
- EFSNet. *Efficient Fast Semantic Segmentation Network.*
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit.*
- Predicción.



EFSNet

EFSNet. *Efficient Fast Semantic Segmentation Network*.

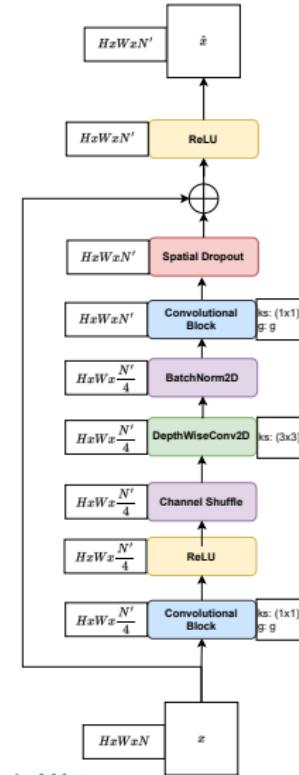
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



EFSNet

- EFSNet. *Efficient Fast Semantic Segmentation Network.*

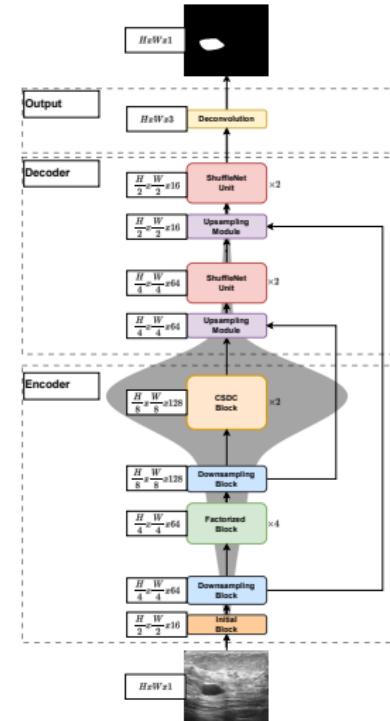
- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- ShuffleNet Unit.*
- Predicción.



EFSNet

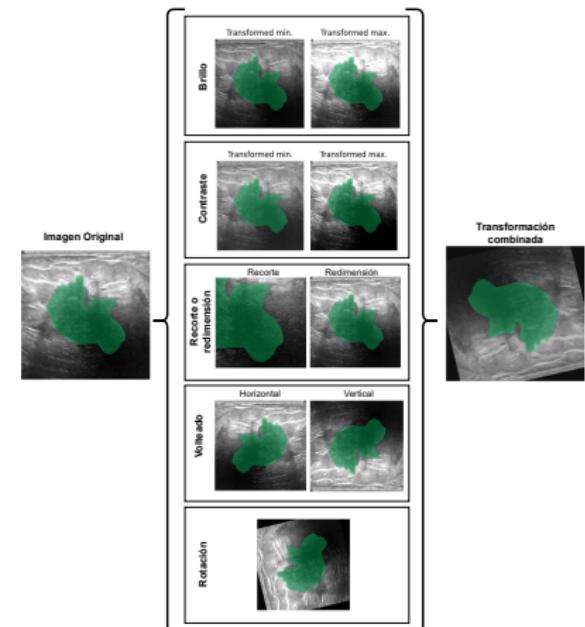
EFSNet. *Efficient Fast Semantic Segmentation Network*.

- Bloque Convolucional.
- Bloque Inicial.
- Bloque *Downsampling*.
- Bloque Factorizado.
- Bloque CSDC.
- Bloque SDC.
- Módulo *Upsampling*.
- *ShuffleNet Unit*.
- Predicción.



Optimización

- Aumento de imágenes
- Función de pérdida
- Pesos por clase
- División de conjuntos de datos
- Entrenamiento y validación



Optimización

- Aumento de imágenes
- Función de pérdida
- Pesos por clase
- División de conjuntos de datos
- Entrenamiento y validación

Entropía Cruzada Categórica

$$\mathcal{L}_{CCE} = - \sum_c^C \omega_c \log \left(\frac{\exp(\hat{x}_{n,c})}{\sum^C \exp(\hat{x}_{n,c})} \right) y_{n,c}$$

Pesos por clase teóricos

$$\omega_c = \frac{1}{\ln(c + p_{class})}$$

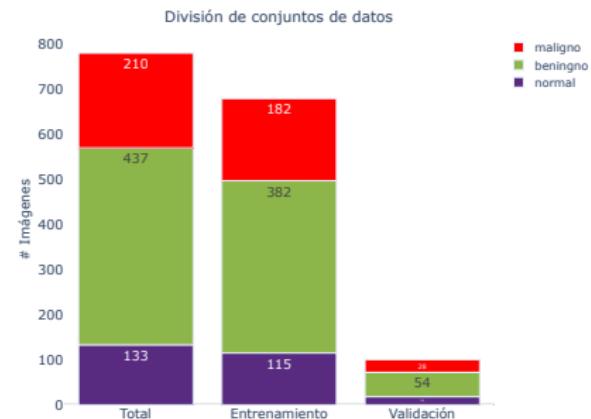
Optimización

- Aumento de imágenes
- Función de pérdida
- Pesos por clase
- División de conjuntos de datos
- Entrenamiento y validación



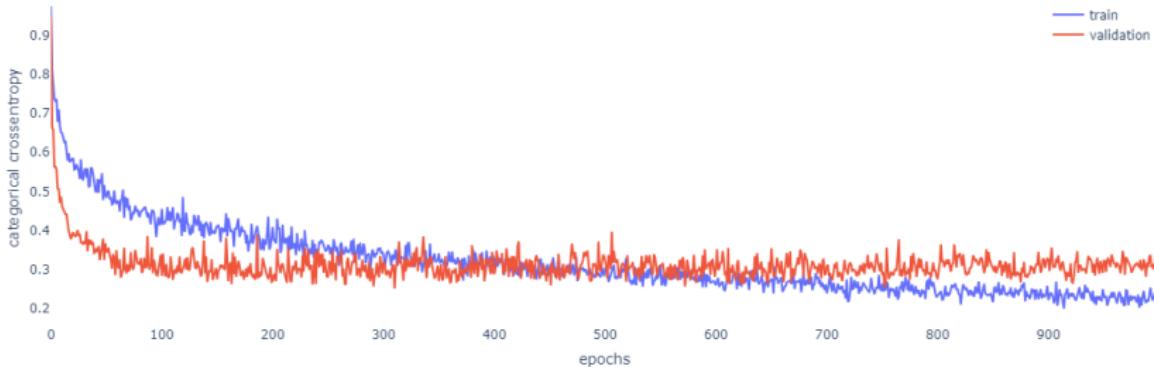
Optimización

- Aumento de imágenes
- Función de pérdida
- Pesos por clase
- División de conjuntos de datos
- Entrenamiento y validación



Optimización

- Aumento de imágenes
- Función de pérdida
- Pesos por clase
- División de conjuntos de datos
- Entrenamiento y validación



Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

4 Resultados

- Métricas obtenidas
- Comparación con el estado del arte
- Análisis visual
- Tiempo Real

5 Conclusiones y Trabajos Futuros

Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

4 Resultados

■ Métricas obtenidas

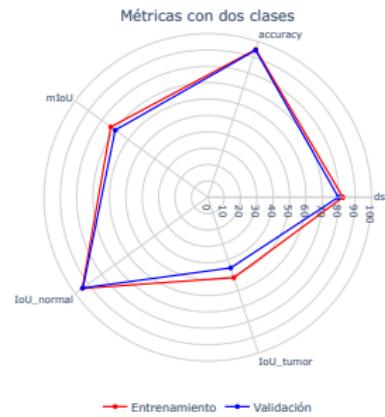
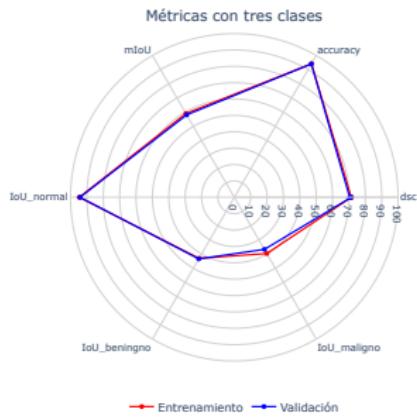
■ Comparación con el estado del arte

■ Análisis visual

■ Tiempo Real

5 Conclusiones y Trabajos Futuros

Métricas



Índice

1 Introducción

2 Estado del Arte

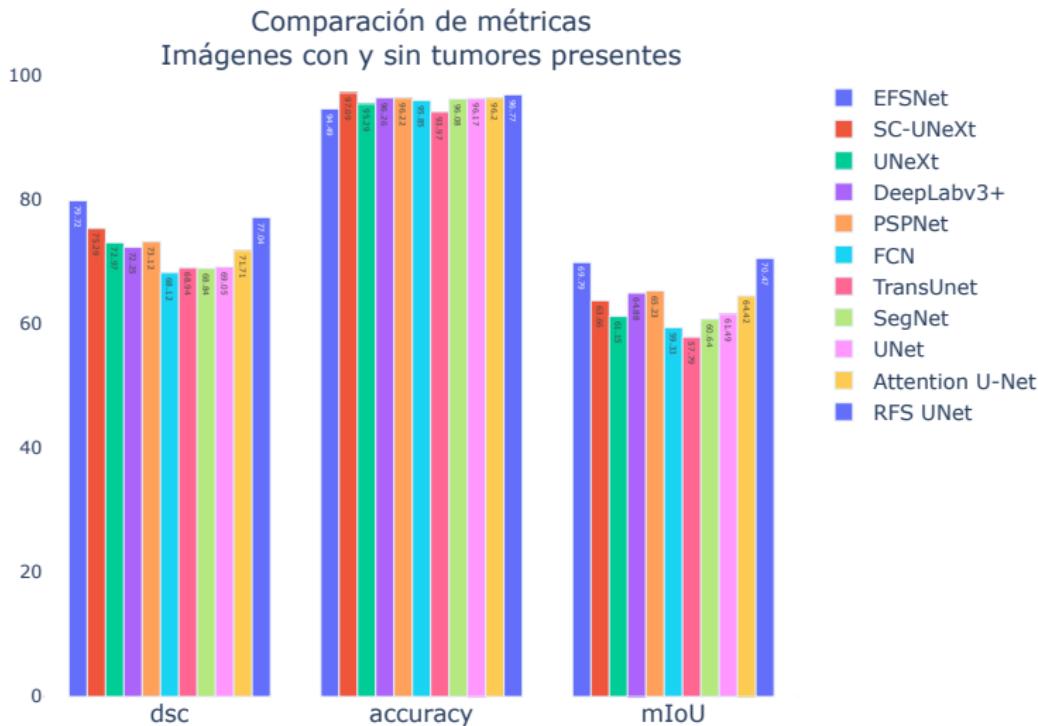
3 Materiales y Métodos

4 Resultados

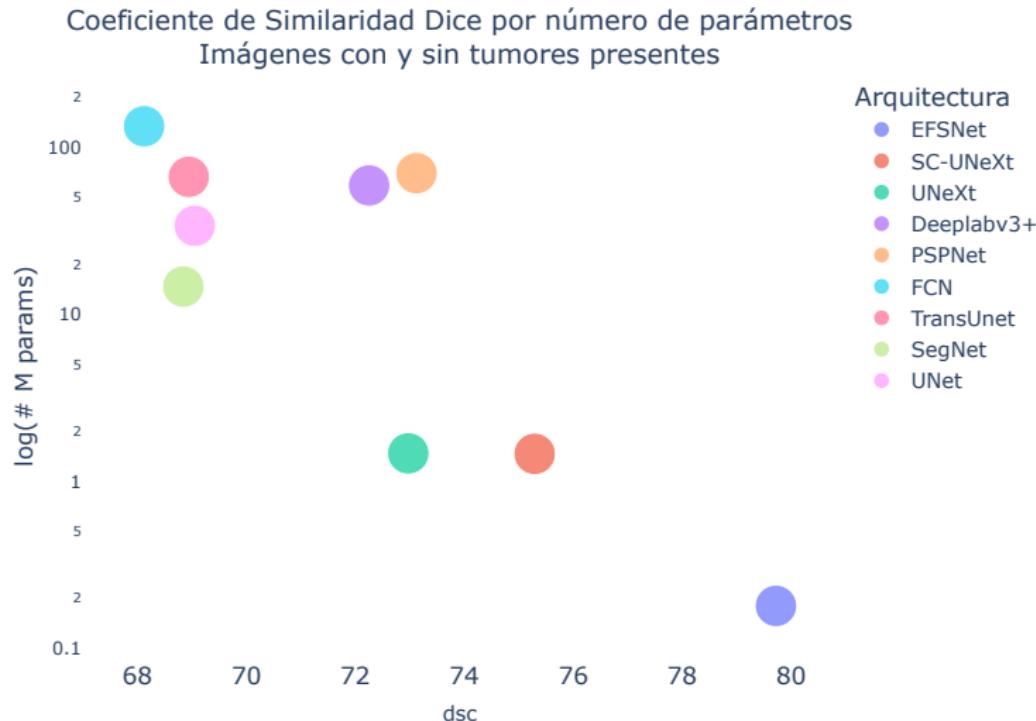
- Métricas obtenidas
- Comparación con el estado del arte
- Análisis visual
- Tiempo Real

5 Conclusiones y Trabajos Futuros

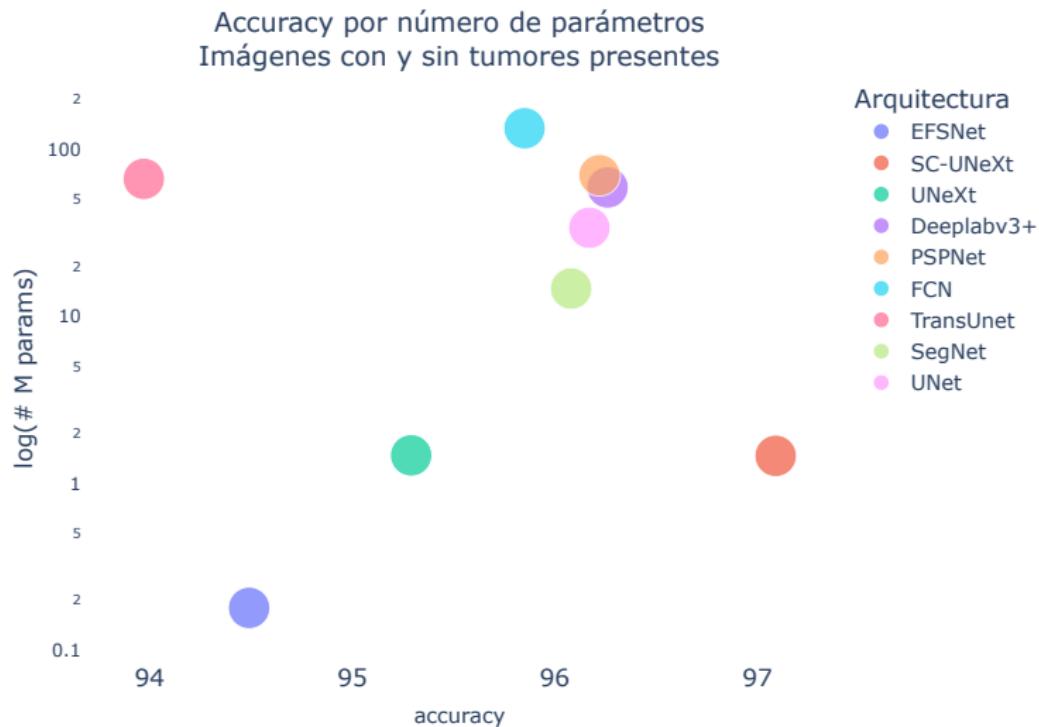
Imágenes con y sin presencia de tumores



Imágenes con y sin presencia de tumores

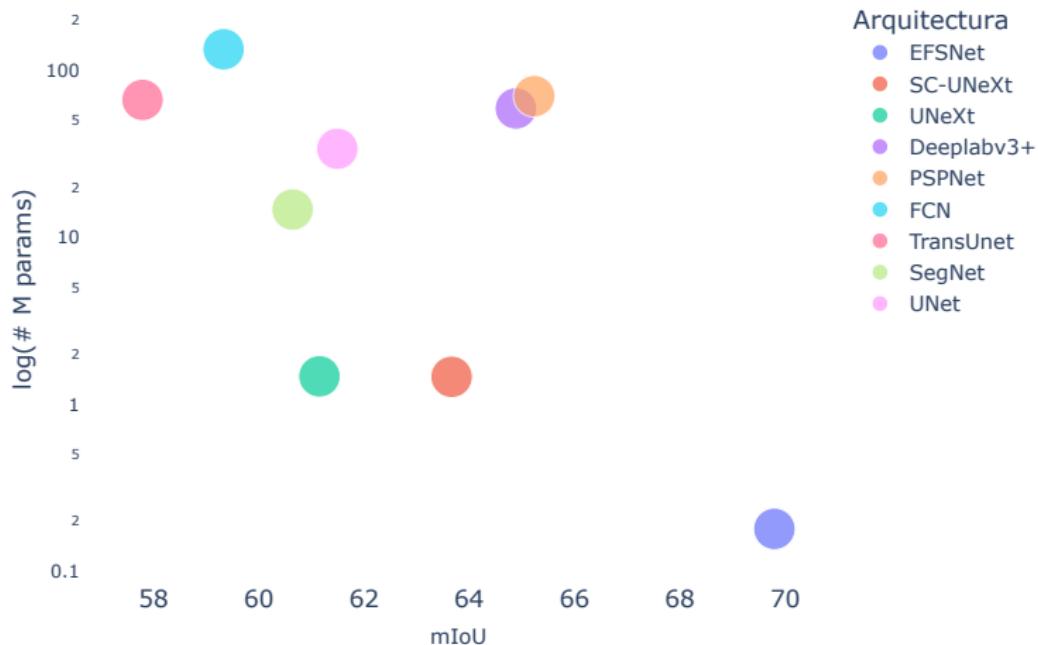


Imágenes con y sin presencia de tumores

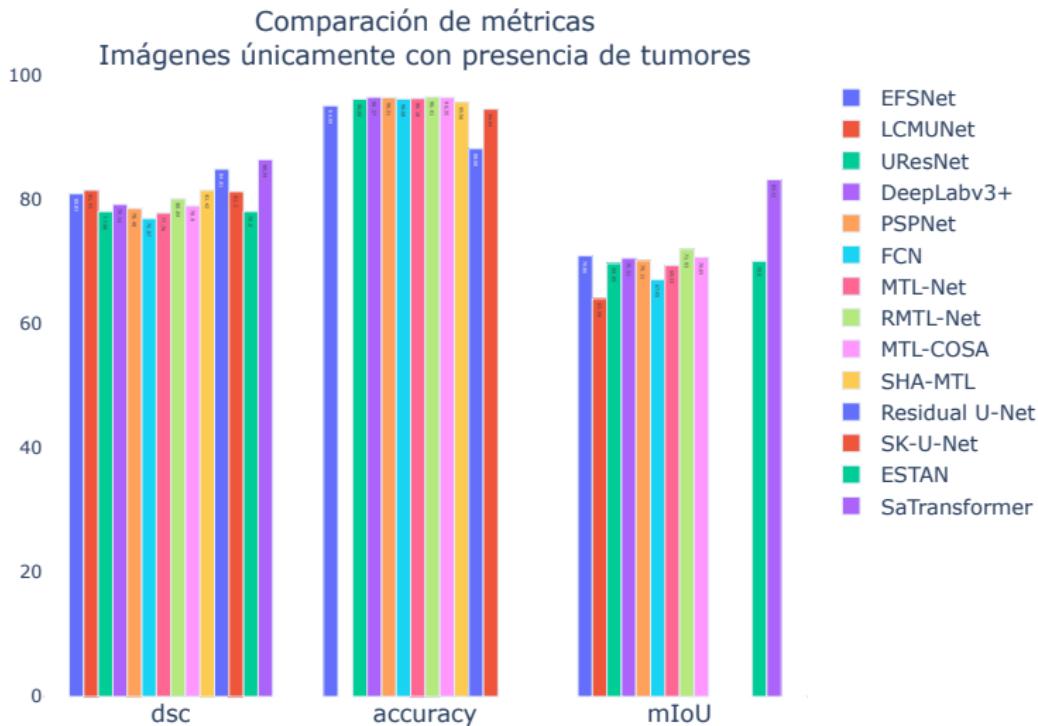


Imágenes con y sin presencia de tumores

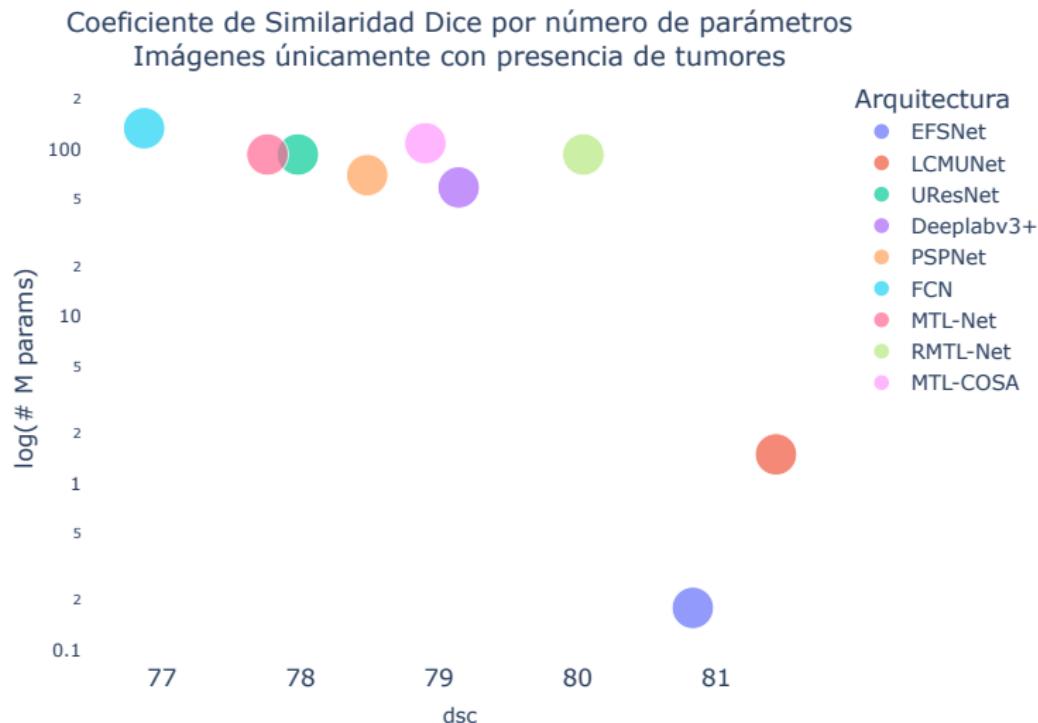
Mean Intersection Over Union por número de parámetros
Imágenes con y sin tumores presentes



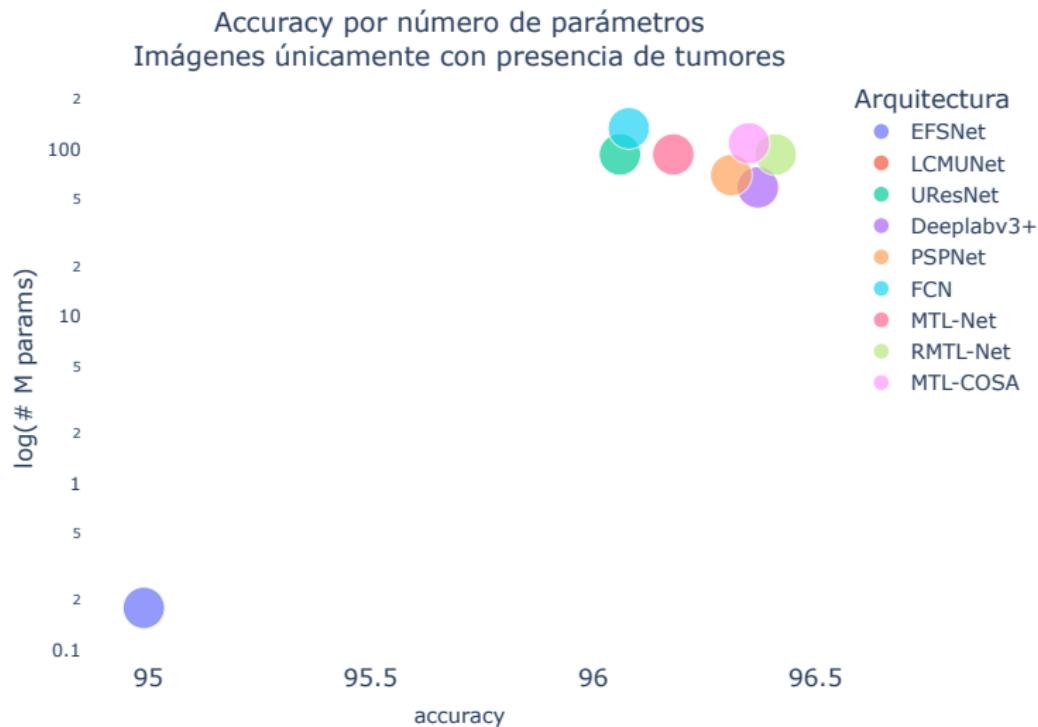
Imágenes únicamente con presencia de tumores



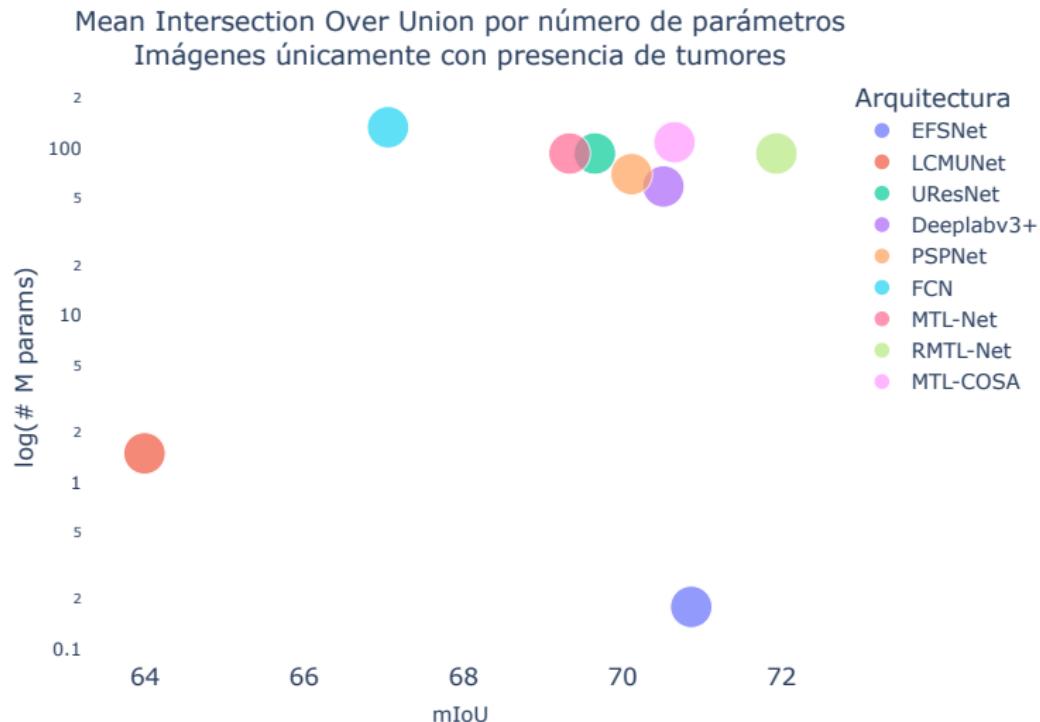
Imágenes únicamente con presencia de tumores



Imágenes únicamente con presencia de tumores



Imágenes únicamente con presencia de tumores



Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

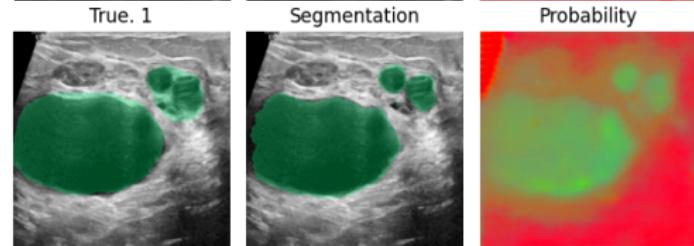
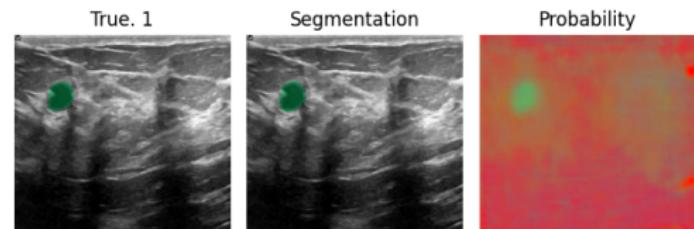
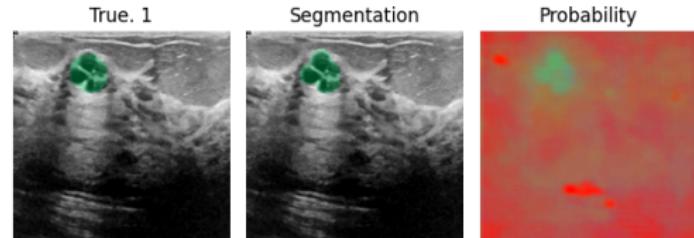
4 Resultados

- Métricas obtenidas
- Comparación con el estado del arte
- **Análisis visual**
- Tiempo Real

5 Conclusiones y Trabajos Futuros

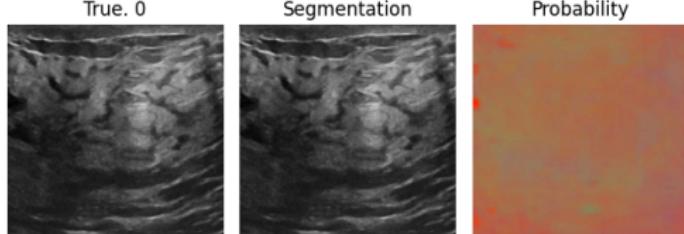
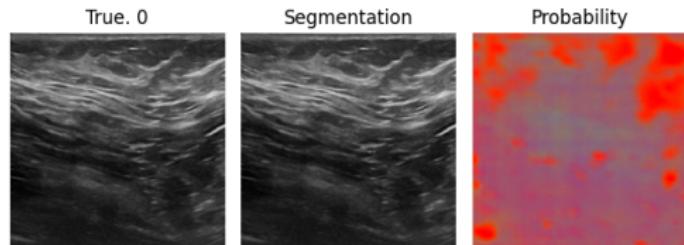
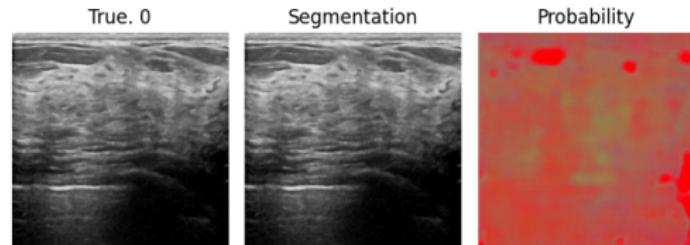
Aciertos

- Tumores benignos pequeños y/o compactos
- Imágenes sin presencia de tumor



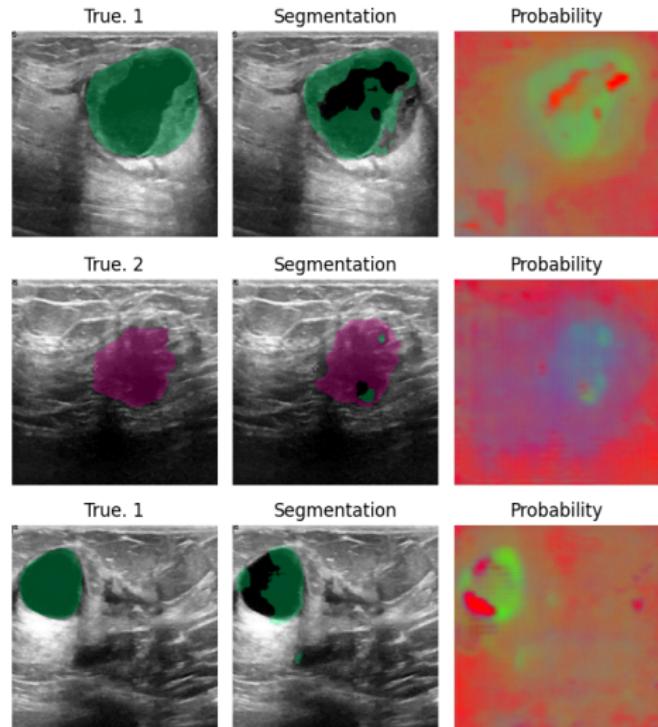
Aciertos

- Tumores benignos pequeños y/o compactos
- Imágenes sin presencia de tumor



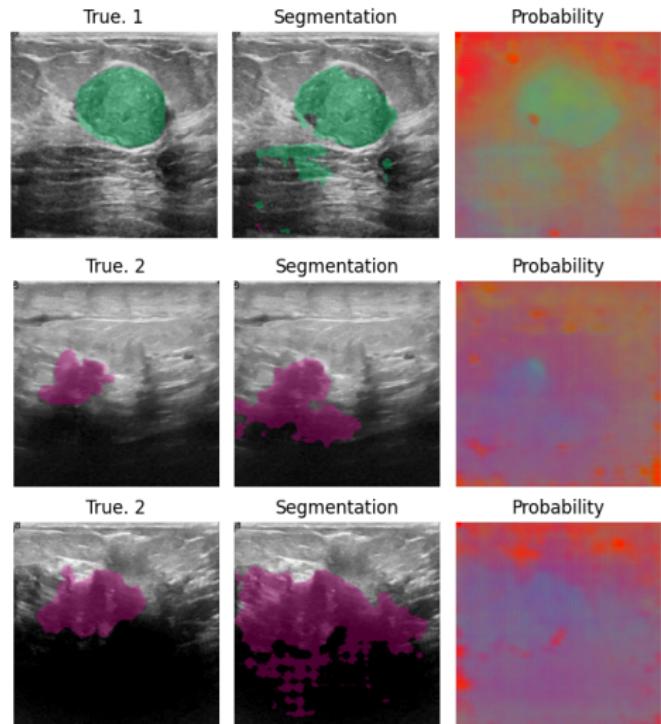
Errores

- Agujeros en las predicciones
- Derrame en las predicciones
- Mezcla o intercambio de clases
- Dudosa veracidad



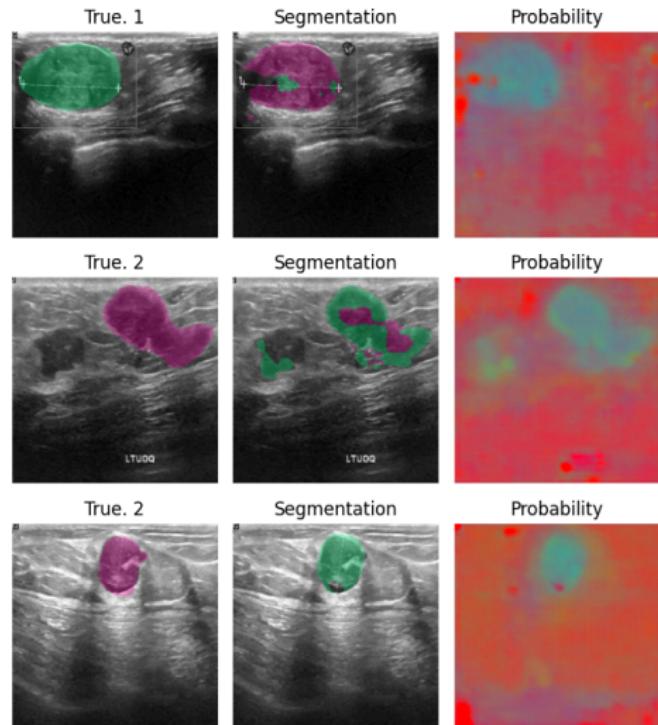
Errores

- Agujeros en las predicciones
- Derrame en las predicciones
- Mezcla o intercambio de clases
- Dudosa veracidad



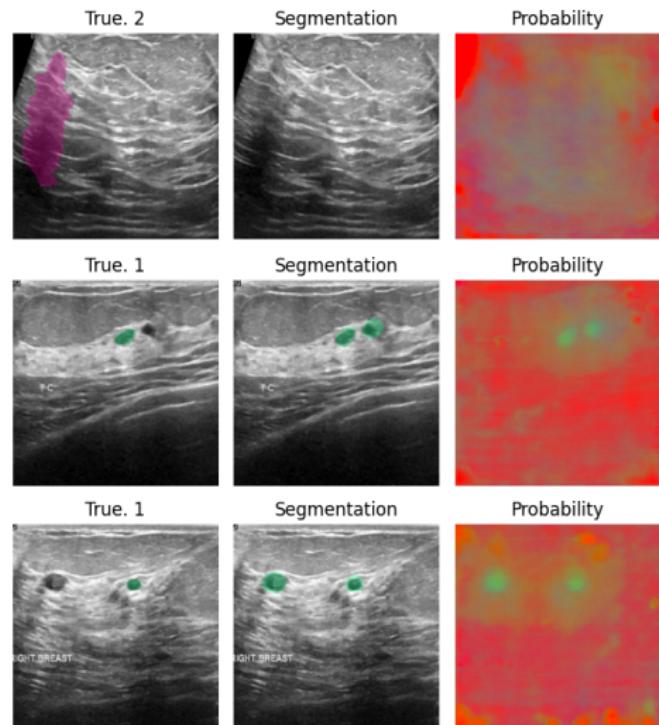
Errores

- Agujeros en las predicciones
- Derrame en las predicciones
- Mezcla o intercambio de clases
- Dudosa veracidad



Errores

- Agujeros en las predicciones
- Derrame en las predicciones
- Mezcla o intercambio de clases
- Dudosa veracidad



Índice

1 Introducción

2 Estado del Arte

3 Materiales y Métodos

4 Resultados

- Métricas obtenidas
- Comparación con el estado del arte
- Análisis visual
- Tiempo Real

5 Conclusiones y Trabajos Futuros

Tiempo Real

Modelo válido para uso en tiempo real.

- NVidia RTX 4060 (*GPU*): 81.6 ± 5.9 FPS
- Intel Core i7 (*CPU*): 10.6 ± 0.5 FPS

Índice

- 1** Introducción
- 2** Estado del Arte
- 3** Materiales y Métodos
- 4** Resultados
- 5** Conclusiones y Trabajos Futuros

Conclusiones

Consecución de objetivos

- Predicciones a la altura del estado del arte e incluso mejores
- Red Neuronal con número de parámetros reducido ($179k$), bajo consumo ($143Mb$) y baja latencia (82 FPS)
- Modelo válido para tiempo real

Ventajas y recomendaciones

Ventajas

- Detección temprana
- Viabilidad de uso en ordenadores convencionales
- Aplicabilidad en otras áreas biomédicas
- Alineamiento con la política de protección de datos (*solución on-premise*)

Recomendación de uso

- Se debe acompañar del criterio de un experto
- Se aconseja inferencia continua para suavizar posibles aberraciones

Ventajas y recomendaciones

Ventajas

- Detección temprana
- Viabilidad de uso en ordenadores convencionales
- Aplicabilidad en otras áreas biomédicas
- Alineamiento con la política de protección de datos (*solución on-premise*)

Recomendación de uso

- Se debe acompañar del criterio de un experto
- Se aconseja inferencia continua para suavizar posibles aberraciones

Trabajo futuro

- Aprendizaje semi-supervisado vía *GAN*.
- Generalización de tareas y despliegue.
- Combinación de conjuntos de datos abiertos.
- Variación de la metodología de aumento y preprocesado de datos.
- Decaimiento de pesos y pérdida *Dice Loss*.
- Segmentación multitarea.

Trabajo futuro

- Aprendizaje semi-supervisado vía *GAN*.
- Generalización de tareas y despliegue.
- Combinación de conjuntos de datos abiertos.
- Variación de la metodología de aumento y preprocesado de datos.
- Decaimiento de pesos y pérdida *Dice Loss*.
- Segmentación multitarea.

Trabajo futuro

- Aprendizaje semi-supervisado vía *GAN*.
- Generalización de tareas y despliegue.
- Combinación de conjuntos de datos abiertos.
- Variación de la metodología de aumento y preprocesado de datos.
- Decaimiento de pesos y pérdida *Dice Loss*.
- Segmentación multitarea.

Trabajo futuro

- Aprendizaje semi-supervisado vía *GAN*.
- Generalización de tareas y despliegue.
- Combinación de conjuntos de datos abiertos.
- Variación de la metodología de aumento y preprocesado de datos.
- Decaimiento de pesos y pérdida *Dice Loss*.
- Segmentación multitarea.

Trabajo futuro

- Aprendizaje semi-supervisado vía *GAN*.
- Generalización de tareas y despliegue.
- Combinación de conjuntos de datos abiertos.
- Variación de la metodología de aumento y preprocesado de datos.
- Decaimiento de pesos y pérdida *Dice Loss*.
- Segmentación multitarea.

Trabajo futuro

- Aprendizaje semi-supervisado vía *GAN*.
- Generalización de tareas y despliegue.
- Combinación de conjuntos de datos abiertos.
- Variación de la metodología de aumento y preprocesado de datos.
- Decaimiento de pesos y pérdida *Dice Loss*.
- Segmentación multitarea.

Bibliografía I

- Impacto del Cáncer de Mama en España. *Red Española de Registros del Cáncer.* [reporte 2024]
- EFSNet: *Xuegang Hu and Haibo Wang. Efficient fast semantic segmentation using continuous shuffle dilated convolutions, 2020.* [paper]
- BUSI Dataset: *Walid Al-Dhabayani, Mohammed Gomaa, Hussien Khaled, and Aly Fahmy. Dataset of breast ultrasound images. 2020.* [paper][Re: crítica]
- Otros Datasets de masas tumorales en ecografías mamarias:
 - OASBUD: *Hanna Piotrzkowska-Wróblewska, Katarzyna Dobruch-Sobczak, Michal Byra, and Andrzej Nowicki. Open access database of raw ultrasonic signals acquired from malignant and benign breast lesions. 2017.* [paper]

Bibliografía II

- UDIAT: *Moi Hoon Yap, Gerard Pons, Joan Martí, Sergi Ganau, Melcior Sentís, Reyer Zwiggelaar, Adrian K. Davison, and Robert Martí. Automated breast ultrasound lesions detection using convolutional neural networks. 2018.* [\[paper\]](#)
- BrEaST: *Anna Pawłowska, Anna wierz Pienkowska, Agnieszka Domalik, Dominika Jagus, Piotr Kasprzak, Rafal Matkowski, Lukasz Fura, Andrzej Nowicki, and Norbert Zolek. Curated benchmark dataset for ultrasound based breast lesion analysis. 2024.* [\[paper\]](#)
- Batch Normalization y sesgo
 - BatchNorm: *Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. 2015.* [\[paper\]](#).

Bibliografía III

- PReLU: *Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. 2015.* [\[paper\]](#)
- Dropout Espacial: *Sanghun Lee and Chulhee Lee. Revisiting spatial dropout for regularizing convolutional neural networks, 2020.* [\[paper\]](#)
- FSSNet: *Xuetao Zhang, Zhenxue Chen, Q. M. Jonathan Wu, Lei Cai, Dan Lu, and Xianming Li. Fast semantic segmentation for scene perception, 2019.* [\[paper\]](#)
- ENet: *Adam Paszke, Abhishek Chaurasia, Sangpil Kim, and Eugenio Culurciello. Enet: A deep neural network architecture for real-time semantic segmentation, 2016.* [\[pre-print\]](#)

Bibliografía IV

- ShuffleNet Unit: *Ningning Ma, Xiangyu Zhang, Hai-Tao Zheng, and Jian Sun. Shufflenet v2: Practical guidelines for efficient CNN Architecture Design.* [\[pre-print\]](#)
- Comparación de métricas de segmentación BUSI en el estado del arte
 - *Meng Xu, Kuan Huang, and Xiaojun Qi. A regional-attentive multi-task learning framework for breast ultrasound image segmentation and classification.* 2023. [\[paper\]](#)
 - *Se Woon Cho, Na Rae Baek, and Kang Ryoung Park. Deep learning-based multistage segmentation method using ultrasound images for breast cancer diagnosis.* Journal of King Saud University - Computer and Information Sciences. 2022. [\[paper\]](#)

Bibliografía V

- *Satish Bansal. Breast tumor recognition by semantic segmentation of multiclass ultrasound images. International Journal on Recent and Innovation Trends in Computing and Communication. 2023.* [\[paper\]](#)
- Aprendizaje Adversario con Segmentación Semántica Semi-Supervisada: *Wei-Chih Hung, Yi-Hsuan Tsai, Yan-Ting Liou, Yen-Yu Lin, and Ming-Hsuan Yang. Adversarial learning for semi-supervised semantic segmentation. 2018.* [\[pre-print\]](#)

Muchas Gracias



Máster Universitario en Investigación en Inteligencia Artificial
J. González-Novo Hueso